



Computational thinking and AI
计算思维与人工智能
兴趣班

北京十一学校 中国科学院计算所
龙溪实验中学

<https://ai-class-shiyilongyue.github.io/>

(六) 机器学习启蒙 ——小小矿石鉴定家

中国科学院计算技术研究所


代 锋

2026.04.08

授课老师简介



Computational thinking and AI
计算思维与人工智能
兴趣班



代 锋


中国科学院计算所研究员
博士生导师

助教：张蔚，罗晨，廖文彬

中国科学院计算所研究员，博士生导师。本科就读于清华大学计算机系，博士毕业于中国科学院计算技术研究所。中国计算机学会多媒体专委会执行委员，长期从事计算机视觉，智慧农业方向的研究工作。

承担了国家重点研发计划课题，国家自然科学基金面上项目等多个国家级项目。在国内外学术期刊和会议上发表论文近百篇，拥有授权发明专利10余项。获得2011年多媒体旗舰会议ICME最佳论文候选，2018年中国多媒体大会最佳论文奖与杰出展示奖。2014年获北京市科学技术一等奖。2022年获得世界物联网博览会金奖。


参与编著《智农融合：人工智能驱动农业新赛道》、《学有所承--研究生毕业传承会撷英》、《大国粮策》等书籍




一、机器学习相关概念介绍

人工智能相关概念

■ 让机器模仿人类的智能，去做原本只有人才能做的事情。



机器学习：目前实现人工智能的主要手段



二、从人类学习开始

人类是如何学习的？

■ 1. 通过规则学习: 规律已知并能准确描述

- 数学：四则混合运算
- 生物：DNA判定物种
- 医学：体脂比判断健康



人类是如何学习的?

■ 1. 通过规则学习: 规律已知并能准确描述

- 数学: 四则混合运算
- 生物: DNA判定物种
- 医学: 体脂比判断健康

CCTAACAGCAGTTATACTAATAGTTTTTCATCATCTGA
GAAGCATTTGCATCTAAACGAGAAGTCTTGACTGTA
GACTTAACCAC

AATCCTCACTAACTCCCAACCTCCTAGGAGACCTAG
CACCTAATCAAGAATCTCTCTACGACGCTGCCGAC
CTACGAGCCGTAGTTAATGCTTCTGACCGAGTACAC
ATCCTAGGA

GATCAGTCCTACCTGATCAAAGTTTAATCCAACAAA
GGGATTAAGGTGATTTGAGGGTTGATGAGGTGGCA
AGAAGCTGAAGATGTTGCGGTAA



规律 $f(x)$



牛
羊
鸭

人类是如何学习的？

■ 1. 通过规则学习: 规律已知并能准确描述

- 数学：四则混合运算
- 生物：DNA判定物种
- 医学：体脂比判断健康



- 男性：10%–20%（健康）； < 10% 偏瘦 / 运动员； > 25% 偏胖
- 女性：20%–30%（健康）； < 18% 偏瘦 / 运动员； > 35% 偏胖

■ 2. 通过经验学习：规律不能或很难准确描述

- 识别物体
- 辨别垃圾短信
- 预测房价



规律 $f(x)$



规律 $f(x)$



苹果

人类是如何学习的?

■ 2. 通过经验学习：规律不能或很难准确描述

- 识别物体
- 辨别垃圾短信
- 预测房价



垃圾短信



正常短信



规律 $f(x)$



规律 $f(x)$

待判定的短信




垃圾短信

正常短信

人类是如何学习的?

■ 2. 通过经验学习：规律不能或很难准确描述

- 识别物体
- 辨别垃圾短信
- 预测房价



大量房屋信息和售价



规律 $f(x)$



待售房屋信息



规律 $f(x)$



售价

小小矿石鉴定家：看例子

■ 仔细观察手上的矿石

– 3人一组，每个小组一份样品



小小矿石鉴定家：选择有效特征

■大家能说出矿石种类的特征吗？

- 颜色？
- 透明度？
- 形状？
- 硬度？
- 成分？

小小矿石鉴定家：总结规律

■如何利用这些特征进行区分？

— 颜色：

- 白、灰、黄、红、绿.....

— 透明度：

- 不透明、有点透明、有的地方有点透明.....

— 形状：

- 好像完全没用

— 硬度：

- 都很硬

— 成分

- 不知道

小小矿石鉴定家：测试

■ 请每组选择一位最厉害的“模型”上来进行测试

答案

■红宝绿 黑曜石 蓝晶砂 蓝晶石 太阳石

■拉长石 绿东陵 拉长石 红宝绿 青金石

■1组: 4

■2组: 3

■3组: 2

■4组: 0

三、机器学习的概念

什么机器学习?

- 计算机从数据中**自动学习规律**，而不需要人为地把每一条规则都写死，从而能对新的、没见过的数据做出判断或预测。
- 计算机自己 “**看例子、提特征、学规律、做判断**”。



机器学习的环节

- 看例子：需要准备大量有标签的数据集（**训练集**），数据集要和模型使用的**场景相近**。



机器学习的环节

- **提特征：** 在传统机器学习时代，特征大多数情况下是人为选择或设计（矿石的颜色等）。在深度学习时代，特征和规律一样通过学习得到。



机器学习的环节

■ 学规律：为事先选择的模型学习参数

– 线性模型 $y = ax + b$ ，二次模型 $y = ax^2 + bx + c$ ，神经网络权重等



机器学习的环节

■ 做判断：运用模型预测测试集的结果，并评估效果



机器学习的分类：分类和回归

■ 分类任务：输出类别

(30%, 男)

(15%, 男)

(30%, 女)



规律 $f(x)$



偏胖
健康
健康

■ 回归任务：输出数值



世纪城远大园六区两居室，视野好，户型...
远大园六区 - 世纪城
2室1厅 | 97.35平米 | 西南 东北 | 精装修 | 中楼层(共12层) | 2000年 | 塔楼
65人关注 / 一年前发布



规律 $f(x)$



售价

重要概念回顾




Computational thinking and AI
计算思维与人工智能
兴趣班

- **训练集**：培训“鉴定师”带标签的矿石（数据+标签）
- **测试集**：测试“鉴定师”能力的矿石（数据+标签）
- **特征**：总结出来的对数据集具有区分度的性质
- **评估指标**：
 - **准确度**：判定正确的数量/测试样本数量

三、决策树体验

开场游戏：猜历史人物



■ 决策树是一种机器学习模型

- 把复杂问题拆成一连串简单小问题
- 每个问题对应一个特征
- 每次选择分得最清楚、最管用的特征先问
- 最终形成一棵树形结构，用来分类或预测



小明的烦恼：今晚能不能玩矿石

- 妈妈最近经常发火，小明决定要观察情形，找出规律，避免遭殃。
- 这是一个什么问题：
 - 分类？回归？
 - 如何收集样本？



豆包AI生成

今天晚上，妈妈会不会发火？

作业写完没	玩手机没	爸爸洗袜子没	妈妈发火不
			发火
			发火
			不发火
			不发火
			发火
			发火
			不发火
			不发火
			发火
			不发火

■ 目标

- 分得最清楚、最管用的特征先问
- 逐个观察特征，选择第一个要问的特征

序号	作业写完没	玩手机没	爸爸洗袜子没	妈妈发火不
1	没写完	玩	没洗	发火
2	写完	玩	洗了	发火
3	没写完	没玩	没洗	不发火
4	写完	没玩	没洗	不发火
5	没写完	玩	洗了	发火
6	写完	玩	没洗	发火
7	没写完	没玩	洗了	不发火
8	写完	没玩	洗了	不发火
9	没写完	玩	没洗	发火
10	写完	玩	洗了	不发火

观察特征：按「作业写完没」分

■ 按「作业写完没」分

– 没写完（1、3、5、7、9）

- 发火：1、5、9
- 不发火：3、7

– 有火有不火，勉强能分一点

– 写完（2、4、6、8、10）

- 发火：2、6
- 不发火：4、8、10

– 也是混在一起

■ 一般般

序号	作业写完没	玩手机没	爸爸洗袜子没	妈妈发火不
1	没写完	玩	没洗	发火
2	写完	玩	洗了	发火
3	没写完	没玩	没洗	不发火
4	写完	没玩	没洗	不发火
5	没写完	玩	洗了	发火
6	写完	玩	没洗	发火
7	没写完	没玩	洗了	不发火
8	写完	没玩	洗了	不发火
9	没写完	玩	没洗	发火
10	写完	玩	洗了	不发火

观察特征：按「有没有玩手机」分

■ 按「有没有玩手机」分

– 玩手机（1、2、5、6、9、10）

- 发火：1、2、5、6、9
- 不发火：10

– 大部分发火，只有一个例外

– 没玩手机（3、4、7、8）

- 发火：0
- 不发火：全部

– 非常干净

■ 这个特征分得明显更清楚

序号	作业写完没	玩手机没	爸爸洗袜子没	妈妈发火不
1	没写完	玩	没洗	发火
2	写完	玩	洗了	发火
3	没写完	没玩	没洗	不发火
4	写完	没玩	没洗	不发火
5	没写完	玩	洗了	发火
6	写完	玩	没洗	发火
7	没写完	没玩	洗了	不发火
8	写完	没玩	洗了	不发火
9	没写完	玩	没洗	发火
10	写完	玩	洗了	不发火

观察特征：按「爸爸洗袜子没」分

■ 按「爸爸洗袜子没」分

— 没洗（1、3、4、6、9）

- 发火：1、6、9
- 不发火：3、4

— 很乱

— 洗了（2、5、7、8、10）

- 发火：2、5
- 不发火：7、8、10

— 也很乱

■ 分得也不好

序号	作业写完没	玩手机没	爸爸洗袜子没	妈妈发火不
1	没写完	玩	没洗	发火
2	写完	玩	洗了	发火
3	没写完	没玩	没洗	不发火
4	写完	没玩	没洗	不发火
5	没写完	玩	洗了	发火
6	写完	玩	没洗	发火
7	没写完	没玩	洗了	不发火
8	写完	没玩	洗了	不发火
9	没写完	玩	没洗	发火
10	写完	玩	洗了	不发火

计算特征区分度

■ 根据上面的直观判断：

■ 玩手机没 > 作业写完没 > 爸爸洗袜子没

■ 电脑如何计算区分度呢？

序号	作业写完没	玩手机没	爸爸洗袜子没	妈妈发火不
1	没写完	玩	没洗	发火
2	写完	玩	洗了	发火
3	没写完	没玩	没洗	不发火
4	写完	没玩	没洗	不发火
5	没写完	玩	洗了	发火
6	写完	玩	没洗	发火
7	没写完	没玩	洗了	不发火
8	写完	没玩	洗了	不发火
9	没写完	玩	没洗	发火
10	写完	玩	洗了	不发火



Gini系数：衡量数据的混乱程度

■ Gini 基尼系数 = 混乱程度

- 数字越小 → 越纯、越整齐
- 数字越大 → 越乱、越杂

$$Gini = 1 - \sum p_i^2$$


- p_i : 数据中第*i*类标签的占比

■ 根节点


$$Gini = 1 - \left(\frac{5}{10}\right)^2 - \left(\frac{5}{10}\right)^2 = 0.5$$

序号	妈妈发火不
1	发火
2	发火
3	不发火
4	不发火
5	发火
6	发火
7	不发火
8	不发火
9	发火
10	不发火


决策树每次选 Gini 最小（下降最多）的特征



计算特征区分度



计算特征区分度



选择策略：采用划分数数据最纯洁的特征

候选特征 (加权 Gini 越小越好)

特征	加权Gini
作业写完没	0.480
玩手机没 ✓	0.167
爸爸洗袜子没	0.480



候选特征 (加权 Gini 越小越好)

特征	加权Gini	下降量
作业写完没 ✓	0.222	0.056
爸爸洗袜子没	0.222	0.056

决策树可视化教学

当前数据源：上传文件：发火.csv。先选标签列，再多选特征列，然后就能根据当前数据重新生成决策树。

教学重点：每到一个节点，都先算"当前节点 Gini"，再比较"剩余属性分裂后的加权 Gini"，谁让 Gini 降得更多，就选谁继续分。

当前特征列

当前选中：作业写完没、玩手机没、爸爸洗袜子没

当前标签列

当前标签列：妈妈发火

当前数据概况

当前使用"上传文件：发火.csv"，共 10 条样本，包含 4 列。

一、数据集与字段选择

选择数据集来源

首版支持 CSV。默认会先载入"带伞"数据集，你也可以上传新的 CSV 文件。

使用默认带伞数据集

上传 CSV 文件

数据集已载入：上传文件：发火.csv

选择用于建树的字段

先选标签列，再多选特征列，然后点击“生成决策树”。首版只支持离散值字段。

标签列（要预测的列）

妈妈发火

特征列（可多选）

☒ 作业写完没

☒ 玩手机没

☒ 爸爸洗袜子没

生成决策树

决策树已通过 Python 服务生成。

补写代码



Computational thinking and AI
计算思维与人工智能
兴趣班

1. 先启动 ``python app.py``
2. 再直接双击打开
``decision_tree_visualization.html``
3. 修改 ``decision_tree.py`` 中的关键函数-
``count_labels``、``calculate_gini``、``split_data``
4. 回到页面点击“生成决策树”，看看生成的对不对
5. 如果浏览器限制本地文件访问，再改用
``python -m http.server 8123``

```
# TODO 1:  
# 统计每个标签出现的次数  
# 提示:  
# 1. 先遍历 data 中的每一条样本  
# 2. 取出该样本的标签值 row[label_key]  
# 3. 用字典累加次数  
  
# TODO 2:  
# 按公式  $Gini = 1 - p_1^2 - p_2^2 - \dots$   
# 计算这一组数据的 Gini 系数  
# 提示:  
# 1. 遍历 label_count 中的每个标签  
# 2. 计算该标签的概率 probability  
# 3. 用 gini 减去 probability * probability  
  
# TODO 3:  
# 按某个特征把数据切成若干组  
# 提示:  
# 1. 遍历每条样本  
# 2. 取出当前样本的特征值 row[feature_key]  
# 3. 如果 groups 中还没有这个键，就先创建空列表  
# 4. 把当前样本追加进去
```

打开程序观察当前例子



如何使用决策树预测

测试路径： 作业写完没： 写完 玩手机没： 玩 爸爸洗袜子没： 没洗 路径已显示 清除路径



如何使用决策树预测

测试路径： 作业写完没： 写完 玩手机没： 玩 爸爸洗袜子没： 没洗 路径已显示 清除路径



使用决策树观察房屋例子



Computational thinking and AI
计算思维与人工智能
兴趣班



留作业：收集数据

成交月份,成交日期,楼座号,面积,朝向,楼层,总楼层,居室,卫生间,报价/万,成交价/万,性质,单价

1月份,2026/1/3,C区,156.78,5,8,23,3,2,950,832.8,满五唯一,5.31

1月份,2026/1/4,A区,67.25,5,1,10,1,1,350,305,满五唯一,4.54

1月份,2026/1/6,C区,89.63,5,19,23,2,1,450,380,满五不唯一,4.24

1月份,2026/1/10,B区,93.67,5,8,12,2,2,560,481,满两年,5.14

1月份,2026/1/10,B区,93.3,5,10,12,2,2,600,515,满五唯一,5.52

谢谢！ 请批评指正！

■ 人工智能与机器学习的关系

■ 机器学习的基本思想和概念

- 了解训练过程；了解数据集、标签、特征概念；了解数据集对特征选取的影响；了解分类和回归任务
- 配合小小矿石鉴定家的交互实验体会分类模型，配合房屋精算师交互体验体会回归模型

■ 分类模型：决策树

- 了解决策树的思想，是通过选择最有区分度的特征进行工作的
- 配合猜动物或者猜教室内物品的游戏
- 能够自己编写程序实现一颗简单的决策树
- 通过coze实现猜动物的程序

■ 回归模型：线性模型

- 了解线性模型的具体形式
- 配合小车滑道游戏体会线性模型的学习过程
- 能够自己编写梯度下降的代码
- 通过coze编写一个网页，可以估计一套房子的价格